

Titulo

Lucio Luque Materazzi, Teo Manuel Kaucher

lluquematerazzi@udesa.edu.ar

tkaucher@udesa.edu.ar

Ingeniería en Inteligencia Artificial

I309 Visión Artificial Avanzada

Otoño 2026

Resumen

Resumeeen

1. Introducción

Intro

donde f_θ representa la red de embeddings parametrizada por θ , K es el número de muestras de soporte por clase, y D^{tr} es el conjunto de soporte.

Luego, la probabilidad de que una imagen de query x pertenezca a la clase n es:

2. Marco teórico

2.1. Conjunto de datos

MNIST MNIST-M SVHN Puede ser con la tabla del informe

$$p_\theta(y = n|\mathbf{x}) = \frac{\exp(-\|f_\theta(\mathbf{x}) - \mathbf{c}_n\|^2)}{\sum_{n'} \exp(-\|f_\theta(\mathbf{x}) - \mathbf{c}_{n'}\|^2)}. \quad (2)$$

2.2. Prototypical Networks

Las *Prototypical Networks* (ProtoNets), propuestas por *Snell et al.* (2017), son un método de *metric-based meta-learning* diseñado para tareas de clasificación *few-shot*. La idea principal consiste en aprender un espacio de embeddings donde ejemplos pertenecientes a una misma clase se agrupen cercanamente.

Durante cada episodio de entrenamiento, el modelo recibe un conjunto de soporte (*support set*) y un conjunto de consulta (*query set*). Para cada clase n , se calcula un prototipo como el promedio de los embeddings de las muestras de soporte:

$$\mathbf{c}_n = \frac{1}{K} \sum_{(x,y) \in D^{\text{tr}}_{y=n}} f_\theta(\mathbf{x}), \quad (1)$$

2.3. MAML

Model-Agnostic Meta-Learning (MAML), propuesto por *Finn et al.* (2017), es un enfoque de *optimization-based meta-learning* cuyo objetivo es aprender una inicialización de parámetros capaz de adaptarse rápidamente a nuevas tareas mediante unas pocas iteraciones de descenso por gradiente.

Durante cada episodio, el modelo realiza una adaptación interna utilizando el conjunto de soporte:

$$\theta'_i = \theta - \alpha \nabla_\theta \mathcal{L}_{\mathcal{T}_i}^{\text{support}}(\theta), \quad (3)$$

donde α es la tasa de aprendizaje interna y θ'_i representa los parámetros adaptados para la tarea $\mathcal{T}_i$.

Posteriormente, se evalúa el desempeño sobre el conjunto de consulta y se optimizan los parámetros originales minimizando:

$$\min_{\theta} \sum_{\mathcal{T}_i} \mathcal{L}_{\mathcal{T}_i}^{query}(\theta'_i). \quad (4)$$

A diferencia de métodos basados en métricas, MAML aprende explícitamente cómo adaptarse mediante gradientes, permitiendo una rápida especialización a nuevas tareas. Sin embargo, el entrenamiento puede resultar inestable y computacionalmente costoso debido al cálculo de gradientes de segundo orden.

2.4. ProtoMAML

ProtoMAML, propuesto por *Triantafyllou et al.* (2020), combina ideas de Prototypical Networks y MAML. El objetivo es aprovechar la estabilidad de los métodos métricos junto con la capacidad de adaptación rápida basada en optimización.

En ProtoMAML, los prototipos calculados a partir del conjunto de soporte se utilizan para inicializar dinámicamente la capa clasificadora antes de realizar las actualizaciones internas de MAML. Dados los prototipos $\mathbf{p}_c$, los pesos y sesgos del clasificador se inicializan como:

$$\mathbf{w}_c = 2\mathbf{p}_c, \quad (5)$$

$$b_c = -\|\mathbf{p}_c\|^2. \quad (6)$$

Luego, el modelo realiza adaptación mediante descenso por gradiente sobre el conjunto de soporte, de manera similar a MAML.

Esta combinación permite partir de representaciones más informativas y mejorar

la convergencia en escenarios *few-shot*, especialmente cuando existen cambios de dominio entre tareas.

2.5. DANN

La *Domain-Adversarial Neural Network* (DANN), propuesta por *Ganin et al.* (2016), es un método de adaptación de dominio cuyo objetivo es aprender representaciones invariantes al dominio.

La arquitectura consta de tres componentes principales:

- Un extractor de características.
- Un clasificador de etiquetas.
- Un clasificador de dominio.

El extractor de características se entrena para minimizar simultáneamente el error de clasificación y maximizar el error del clasificador de dominio. Esto se logra mediante una capa denominada *Gradient Reversal Layer* (GRL), que invierte el signo del gradiente durante la retropropagación.

La función objetivo puede expresarse como:

$$\mathcal{L}_{DANN} = \mathcal{L}_{task} - \lambda \mathcal{L}_{domain}, \quad (7)$$

donde $\mathcal{L}_{task}$ corresponde a la pérdida de clasificación principal y $\mathcal{L}_{domain}$ a la pérdida del discriminador de dominio.

El objetivo es obtener embeddings que contengan información útil para la clasificación, pero que no permitan distinguir entre dominios fuente y objetivo. Esto favorece la generalización bajo *domain shift*.

3. Desarrollo

4. Resultados

4.1. Prototypical Networks




Figura 1: caption




Figura 2: caption

¿Se forman clusters separados? ¿Cómo evoluciona la estructura a medida que avanza el entrenamiento?




Figura 3: caption




Figura 4: caption

¿Están los embeddings de los mismos dígitos cerca entre dominios? ¿Qué implica esto para la clasificación episódica cross-domain?

4.2. MAML y ProtoMAML




Figura 5: caption

registrar seis métricas: accuracies pre y post-adaptación en support, y post-adaptación en query, en entrenamiento y validación. Graficar la accuracy post-adaptación en validación durante el entrenamiento.




Figura 6: caption

No lo piden

4.3. Prototypical Networks, ProtoMAML y ProtoMAML




Figura 7: caption

A cami le da mejor protomaml que todos




Figura 8: caption

Visualización del espacio latente comparativa: proyectar los embeddings del encoder para imágenes de MNIST, MNIST-M y SVHN en el mismo gráfico, usando el encoder

de cada modelo. Colorear por dominio. ¿Qué modelo produce embeddings más cercanos entre dominios? ¿Se corresponde con la accuracy cross-domain?

NOSE MUY BIEN COMO MOSTRARLOS ESTE ES SOLO UNO DE LOS MODELOS HABRIA QUE PREGUNTAR BIEN COMO

4.4. DANN




Figura 9: caption

Graficar en el mismo plot la loss de clasificación, la loss de dominio y la accuracy en MNIST-M a lo largo del entrenamiento, para DANN y el baseline. ¿Cómo evolucionan en relación la una con la otra?

	MNIST (%)	MNIST-M (%)	SVHN (%)
Baseline	99.51	56.45	28.74
Baseline ft	98.52	97.48	30.44
DANN	99.19	88.69	33.76

Cuadro 1: caption

No piden ni SVHN ni Baseline ft, que hacemos?




Figura 10: caption




Figura 11: caption




Figura 12: caption

SE PODRIAN JUNTAR LOS 3 EN UNO SOLO?

5. Conclusión

6. Bibliografía